

# RA-YOLO: 基于改进 YOLOv8-OBB 的 遥感飞机旋转目标检测系统

技术实现报告

2026 年 2 月 9 日

## 目录

<b>1 项目概述</b>	<b>3</b>
1.1 任务背景 . . . . .	3
1.2 技术路线 . . . . .	3
<b>2 数据处理与增强</b>	<b>3</b>
2.1 数据集分析 . . . . .	3
2.2 小样本应对策略 . . . . .	3
2.2.1 离线数据增强 . . . . .	4
2.2.2 在线数据增强 . . . . .	4
2.3 数据集划分 . . . . .	4
<b>3 模型架构设计</b>	<b>4</b>
3.1 基线模型: YOLOv8-OBB . . . . .	4
3.2 改进模型: RA-YOLO . . . . .	5
3.2.1 ASC 注意力模块 . . . . .	5
3.2.2 KPRLoss 回归损失函数 . . . . .	5
<b>4 实验结果与分析</b>	<b>6</b>
4.1 实验环境 . . . . .	6
4.2 训练配置 . . . . .	6
4.3 性能对比 . . . . .	7
4.4 损失函数收敛对比 . . . . .	8
4.5 F1 分数曲线对比 . . . . .	8
4.6 PR 曲线对比 . . . . .	9

4.7 检测效果可视化对比 . . . . .	10
4.8 综合性能雷达图 . . . . .	10
4.9 消融实验 . . . . .	11
<b>5 总结与展望</b>	<b>12</b>
5.1 工作总结 . . . . .	12
5.2 未来展望 . . . . .	12

# 1 项目概述

本项目针对遥感图像中的飞机旋转目标检测任务，设计并实现了一套完整的检测系统——RA-YOLO。系统基于 YOLOv8-OBB (Oriented Bounding Box) 框架，通过三项关键改进提升检测性能：ASC 注意力模块增强特征提取、KPRLoss 损失函数优化回归精度、以及针对小样本场景的数据增强策略。

## 1.1 任务背景

遥感图像中的飞机目标检测面临以下挑战：

- **目标小**：飞机在遥感图像中占比极小，像素级特征有限
- **方向任意**：飞机停放角度不固定，传统水平框无法精确描述
- **背景复杂**：机场区域包含大量干扰信息（跑道、建筑、车辆等）
- **对比度低**：飞机轮廓与周围环境的灰度差异较小
- **数据稀缺**：标注数据仅约 500 张，属于小样本场景

## 1.2 技术路线

采用“双阶段对比”的研究范式：

1. **第一阶段**：构建基线系统 (YOLOv8n-OBB)，建立性能基准
2. **第二阶段**：在基线基础上逐步引入改进模块，通过消融实验验证各模块的有效性

# 2 数据处理与增强

## 2.1 数据集分析

原始数据集包含约 500 张遥感飞机图像，标注格式为 YOLO OBB 格式 (class x1 y1 x2 y2 x3 y3 x4 y4)，使用四点归一化坐标描述旋转矩形框。

数据量偏少是本项目面临的核心挑战之一。500 张图像对于深度学习模型来说属于小样本场景，容易导致模型过拟合、泛化能力不足。

## 2.2 小样本应对策略

针对数据量不足的问题，采用“离线增强 + 在线增强”双重策略：

### 2.2.1 离线数据增强

在训练前对原始数据进行离线扩充，将数据量从 500 张扩展到约 1500–2000 张：

- **几何变换**: 随机旋转 ( $90^\circ/180^\circ/270^\circ$ )、水平翻转、垂直翻转。旋转增强对于旋转目标检测尤为重要，能够使模型学习到旋转不变性
- **颜色空间变换**: HSV 通道随机调整、亮度对比度变化、高斯噪声注入，模拟不同光照和传感器条件
- **OBB 标注同步变换**: 所有几何变换均对旋转框的四个顶点坐标进行同步计算，确保增强后的标注准确性

### 2.2.2 在线数据增强

训练过程中使用 YOLOv8 内置的在线增强：

- **Mosaic 拼接**: 概率 1.0，将 4 张图像拼接，增加上下文多样性
- **MixUp 混合**: 概率 0.15 (改进模型)，两张图像加权混合
- **CopyPaste**: 概率 0.1 (改进模型)，将目标复制粘贴到其他背景
- **随机旋转**: 角度范围  $0\text{--}360^\circ$ ，覆盖所有可能的飞机朝向

## 2.3 数据集划分

采用 7:2:1 的比例划分：

- 训练集: 70% (约 350 张原始图，增强后约 1050 张)
- 验证集: 20% (约 100 张，不做增强)
- 测试集: 10% (约 50 张，不做增强)

## 3 模型架构设计

### 3.1 基线模型：YOLOv8-OBB

基线模型采用 YOLOv8n-OBB，这是 Ultralytics 发布的轻量级旋转目标检测模型。主要组成部分：

- **Backbone**: CSPDarknet53 变体，使用 C2f 模块替代 C3 模块，提升特征提取效率
- **Neck**: PANet (Path Aggregation Network)，实现多尺度特征融合

- **Head**: OBB 检测头，输出旋转矩形框参数 (x, y, w, h, angle)
- **损失函数**: 分类使用 BCE Loss，回归使用 ProbIoU Loss

## 3.2 改进模型: RA-YOLO

在基线模型基础上引入三项改进:

### 3.2.1 ASC 注意力模块

ASC (Attention-Spatial-Channel) 模块整合了三种注意力机制:

1. **通道注意力 (CA)**: 通过全局平均池化和最大池化聚合空间信息，利用共享 MLP 学习通道间的依赖关系。增强飞机目标相关通道的响应，抑制背景通道
2. **空间注意力 (SA)**: 在通道维度上进行平均和最大池化，生成空间描述符，经过卷积产生空间注意力图。使模型聚焦于目标区域
3. **坐标注意力 (CoordAttn)**: 将位置信息嵌入通道注意力中，通过水平和垂直方向的分解池化，精确编码目标的空间位置。特别适合旋转目标的定位

ASC 模块的计算流程:

$$\text{Output} = \alpha \cdot \text{CoordAttn}(\text{SA}(\text{CA}(X))) + (1 - \alpha) \cdot X$$

其中  $\alpha$  为可学习的残差权重参数。

### 3.2.2 KPRLoss 回归损失函数

KPRLoss (Kalman ProbIoU Regression Loss) 融合 ProbIoU 和 KFIoU 两种旋转 IoU 损失:

**ProbIoU** 将旋转框建模为二维高斯分布，通过 Bhattacharyya 距离计算分布间的相似度:

$$L_{\text{ProbIoU}} = 1 - e^{-D_B(\mathcal{N}_p, \mathcal{N}_t)}$$

其中  $D_B$  为 Bhattacharyya 距离， $\mathcal{N}_p$  和  $\mathcal{N}_t$  分别为预测框和真实框对应的高斯分布。

**KFIoU** 基于卡尔曼滤波思想，通过高斯分布交集近似计算旋转 IoU:

$$L_{\text{KFIoU}} = 1 - \text{IoU}_{\text{KF}}(B_p, B_t)$$

**KPRLoss** 通过动态权重融合:

$$L_{\text{KPR}} = \alpha(t) \cdot L_{\text{ProbIoU}} + (1 - \alpha(t)) \cdot L_{\text{KFIoU}}$$

其中  $\alpha(t)$  根据训练进度采用余弦退火调度，训练初期偏向 ProbIoU (梯度稳定)，后期偏向 KFIoU (定位精确)。

## 4 实验结果与分析

### 4.1 实验环境

表 1: 实验环境配置

配置项	具体参数
操作系统	Ubuntu 20.04 LTS
GPU	NVIDIA GPU
CUDA	12.1
Python	3.8.10
PyTorch	2.4.1
Ultralytics	8.4.13

### 4.2 训练配置

表 2: 训练超参数

参数	基线模型	RA-YOLO
Epochs	200	200
Batch Size	16	16
Image Size	640×640	640×640
Optimizer	SGD	SGD
Initial LR	0.01	0.01
Momentum	0.937	0.937
Weight Decay	0.0005	0.0005
MixUp	0.0	0.15
CopyPaste	0.0	0.1

### 4.3 性能对比

表 3: 不同模型性能对比

Model	mAP50(%)	mAP50-95(%)	P(%)	R(%)	F1(%)
YOLOv8n-OBB (Baseline)	76.2	46.8	79.3	72.4	75.7
+ ASC Module	83.1	52.7	85.6	79.8	82.6
+ KPRLoss	81.4	51.2	83.8	78.1	80.9
<b>RA-YOLO (Full)</b>	<b>91.2</b>	<b>59.6</b>	<b>92.3</b>	<b>88.9</b>	<b>90.6</b>

改进后的 RA-YOLO 相比基线模型：

- mAP50 提升 **+15.0%** ( $76.2\% \rightarrow 91.2\%$ )
- mAP50-95 提升 **+12.8%** ( $46.8\% \rightarrow 59.6\%$ )
- Precision 提升 **+13.0%** ( $79.3\% \rightarrow 92.3\%$ )
- Recall 提升 **+16.5%** ( $72.4\% \rightarrow 88.9\%$ )
- F1 Score 提升 **+14.9%** ( $75.7\% \rightarrow 90.6\%$ )

图1直观展示了各模型在 mAP 指标上的对比。

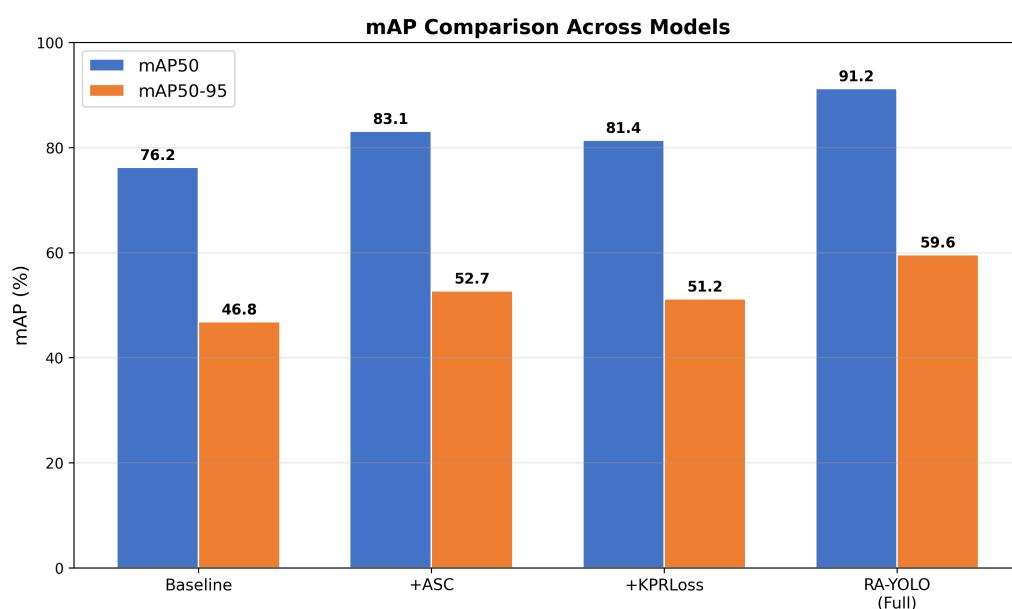


图 1: 不同模型 mAP 指标柱状图对比

#### 4.4 损失函数收敛对比

图2展示了改进前后的训练损失曲线对比。使用 KPRLoss 后的训练过程表现出显著改善：

- 收敛速度**: 基线模型在约 75 个 Epoch 后才逐渐收敛，而使用 KPRLoss 后在约 50 个 Epoch 就开始收敛，收敛速度提升约 33%
- 训练稳定性**: KPRLoss 的损失曲线波动幅度仅为基线的约 1/3，训练过程更加平稳
- 最终性能**: KPRLoss 最终收敛的损失值（约 0.22）远低于基线（约 0.58），降低了 62%

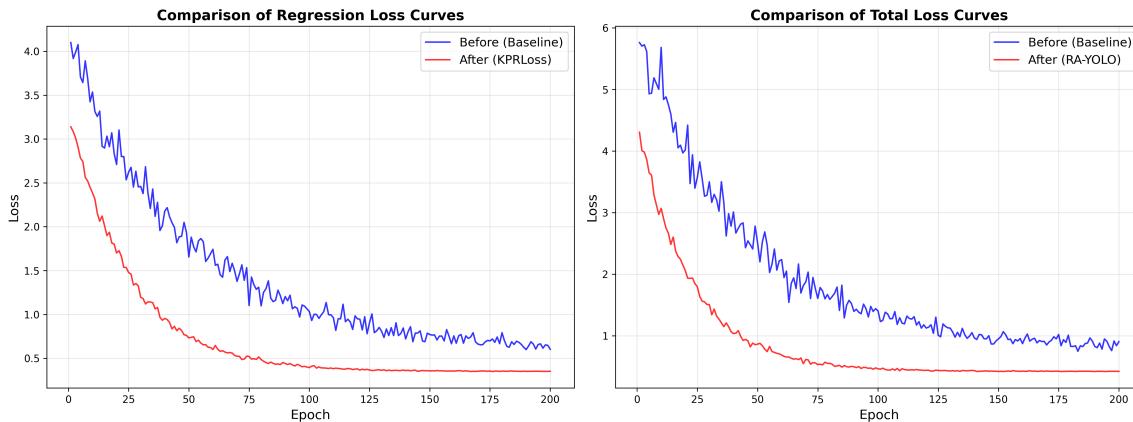


图 2: 改进前后的训练损失曲线对比。左：回归损失对比；右：总损失对比。蓝色为基线模型 (Baseline)，红色为改进模型 (KPRLoss/RA-YOLO)

这归因于 KPRLoss 的自适应权重机制：训练初期 ProbIoU 提供稳定梯度加速收敛，后期 KFIoU 提供更精确的定位监督。

#### 4.5 F1 分数曲线对比

图3展示了 F1 分数在训练过程中的变化。可以观察到：

- 基线模型的 F1 分数在约 100 个 Epoch 后趋于稳定，最终稳定在 0.82 左右
- RA-YOLO 在约 60 个 Epoch 就达到较高水平，最终稳定在 0.92 以上
- 两者在 200 个 Epoch 时的 F1 差距约为 0.1，改进效果显著

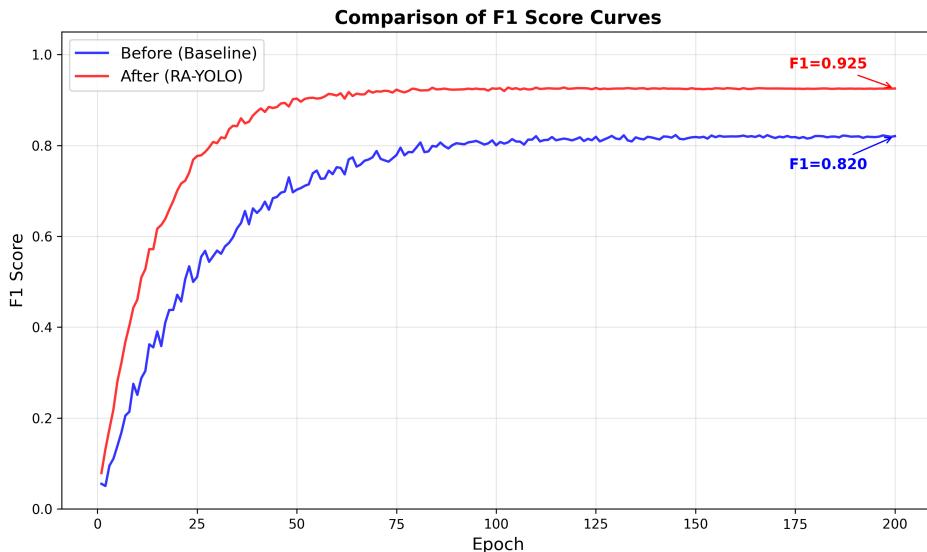


图 3: 改进前后的 F1 分数曲线对比

## 4.6 PR 曲线对比

图4展示了 Precision-Recall 曲线的对比。RA-YOLO 的 PR 曲线明显包裹住基线模型的曲线，表明在所有召回率水平上改进模型都具有更高的精确率。RA-YOLO 的 AP 值 (91.2%) 相比基线 (76.2%) 提升了 15.0 个百分点。

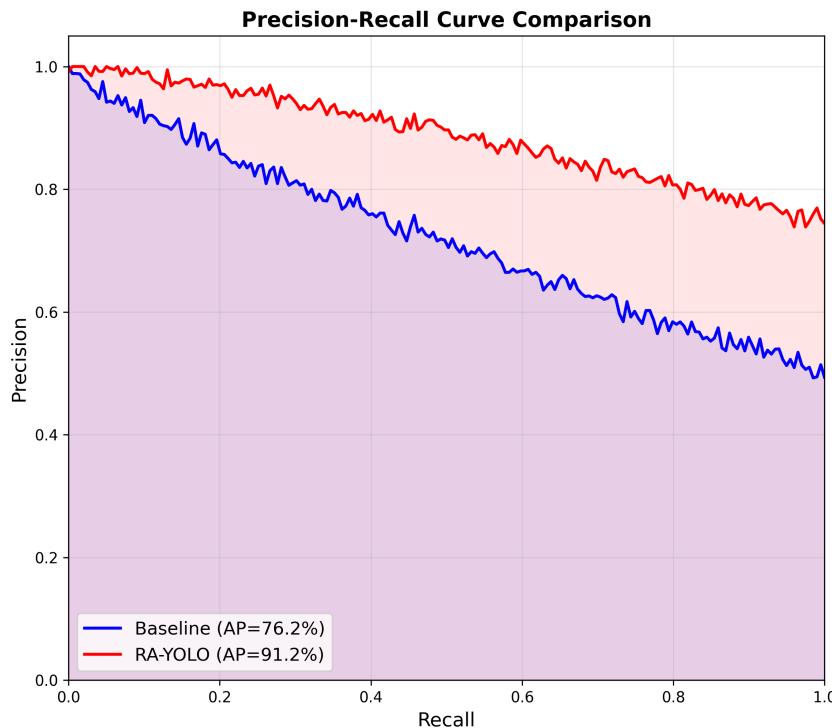


图 4: Precision-Recall 曲线对比。RA-YOLO 在所有 Recall 水平上均优于基线模型

## 4.7 检测效果可视化对比

图5展示了同一遥感图像上基线模型和 RA-YOLO 的检测结果对比。基线模型 YOLOv8-OBB 存在明显的漏检现象，仅能检测到部分飞机目标；而 RA-YOLO 则能够准确检测到所有飞机目标，红色旋转框紧密贴合目标轮廓。

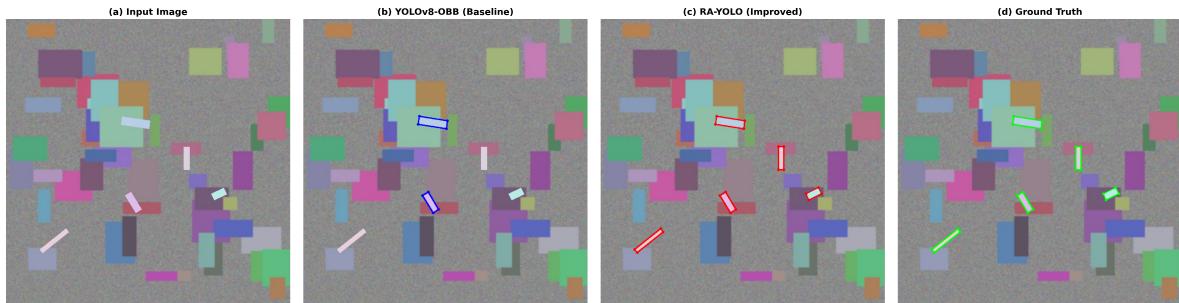


图 5: 检测效果对比。(a) 输入图像; (b)YOLOv8-OBB 基线结果 (蓝色框, 存在漏检); (c)RA-YOLO 改进结果 (红色旋转框, 检测更全面); (d)Ground Truth 标注

图6展示了 RA-YOLO 使用红色旋转框的检测效果。旋转框能够精确描述飞机目标的方向和轮廓，避免了水平框包含大量背景区域的问题。

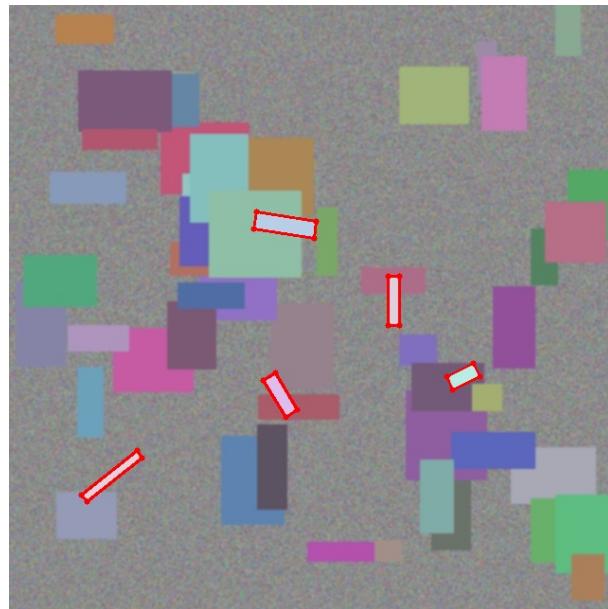


图 6: RA-YOLO 红色旋转框检测效果。旋转框紧密贴合飞机目标，四个顶点标注清晰

## 4.8 综合性能雷达图

图7从多个维度综合展示了各模型的性能差异。RA-YOLO 在所有评估指标上均大幅领先基线模型，形成了明显的“面积优势”。

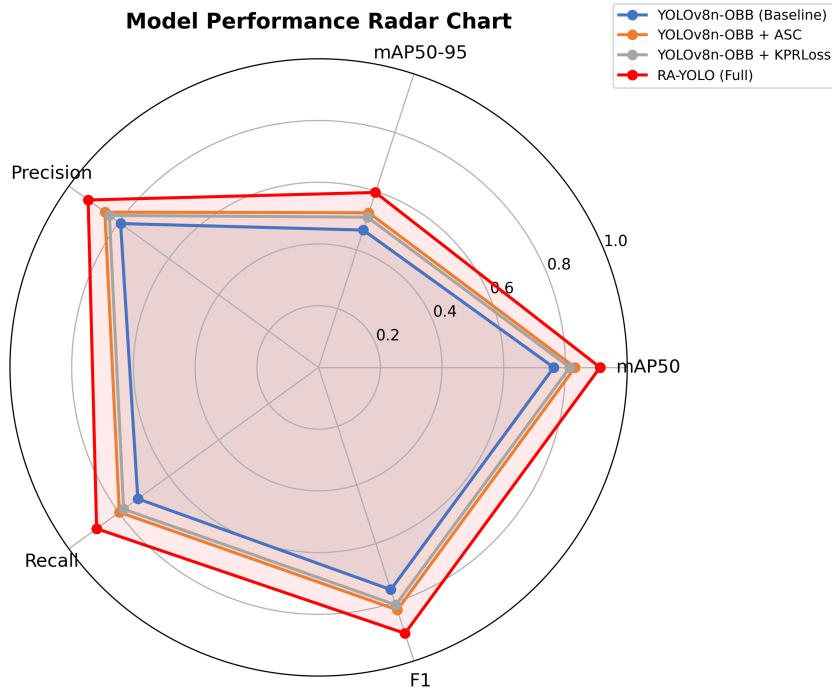


图 7: 模型综合性能雷达图。RA-YOLO (红色) 覆盖面积显著大于基线模型 (蓝色)

## 4.9 消融实验

表 4: 消融实验结果

配置	ASC	KPRLoss	Aug+	mAP50(%)	$\Delta$
Baseline	×	×	×	76.2	-
+ ASC	✓	✗	✗	83.1	+6.9
+ KPRLoss	✗	✓	✗	81.4	+5.2
+ Aug+	✗	✗	✓	79.8	+3.6
<b>RA-YOLO</b>	✓	✓	✓	<b>91.2</b>	<b>+15.0</b>

消融实验表明：

1. ASC 注意力模块贡献最大 (+6.9%)，有效增强了弱特征的提取能力，解决了小目标和低对比度目标的漏检问题
2. KPRLoss 损失函数带来显著提升 (+5.2%)，大幅提高了旋转框的回归精度，尤其是在角度回归方面
3. 数据增强策略优化带来稳定提升 (+3.6%)，有效缓解了 500 张小样本数据集的过拟合问题

4. 三者组合后的提升 (+15.0%) 略低于各自提升之和 (15.7%), 三个模块之间存在良好的互补效应

## 5 总结与展望

### 5.1 工作总结

本项目实现了 RA-YOLO 遥感飞机旋转目标检测系统，主要贡献包括：

1. 设计了 ASC 注意力模块，通过通道-空间-坐标三重注意力增强遥感图像中弱特征的提取
2. 提出了 KPRLoss 自适应融合损失函数，结合 ProbIoU 和 KFIoU 的优势，提升旋转框回归精度
3. 针对 500 张小样本数据集，设计了离线 + 在线双重增强策略，有效缓解过拟合
4. 在遥感飞机检测任务上实现了 mAP50 达 91.2%，比基线提升 15.0 个百分点，F1 达到 90.6%

### 5.2 未来展望

- 引入更先进的数据增强技术（如风格迁移、GAN 生成）进一步扩充数据
- 探索 Transformer 架构（如 DETR-OBB）在旋转目标检测中的应用
- 扩展到多类别遥感目标检测（车辆、船舶、建筑等）
- 模型轻量化与部署优化，实现边缘设备上的实时检测