

RA-YOLO 技术决策说明书

——为什么这么实现

设计原理与技术选型分析

2026 年 2 月 9 日

目录

1 引言	3
2 为什么选择旋转框（OBB）而不是水平框	3
2.1 问题本质	3
2.2 为什么选择四点坐标格式	4
3 为什么选择 YOLOv8-OBB 作为基线框架	4
3.1 框架对比考量	4
3.2 关于“双阶段”的理解	5
4 为什么设计 ASC 注意力模块	5
4.1 问题诊断	5
4.2 为什么不直接用 CBAM 或 SE	6
4.3 残差连接的设计	6
5 为什么设计 KPRLoss 损失函数	7
5.1 旋转框回归的核心难题	7
5.2 现有损失函数的局限	7
5.3 KPRLoss 的设计思路	7
6 为什么采用这样的数据增强策略	8
6.1 500 张数据的困境	8
6.2 增强策略的选择逻辑	8
7 为什么采用红色旋转框进行可视化	8
8 改进效果的综合验证	9

9 项目结构为什么这样组织 10

10 总结 10

1 引言

这份文档从我的第一视角出发，详细说明在构建 RA-YOLO 遥感飞机旋转目标检测系统时，每个关键技术决策背后的思考过程和选择依据。不是简单地罗列“用了什么”，而是解释“为什么这么做”。

2 为什么选择旋转框（OBB）而不是水平框

2.1 问题本质

拿到这个遥感飞机检测任务后，我首先思考的是标注形式的选择。水平框（HBB）是最简单的方案，但在遥感场景下存在根本性缺陷。

飞机是一种细长型目标，长宽比通常在 3:1 到 5:1 之间。当飞机以斜 45 度停放时，水平框需要包含大量背景区域才能框住目标，导致：

- 目标区域占比低（有效像素可能不到框面积的 30%）
- 相邻飞机的水平框严重重叠，NMS 容易误抑制
- 无法获取飞机的朝向信息

旋转框（OBB）直接用四个顶点坐标或中心点 + 宽高 + 角度来描述目标，能紧密贴合飞机的实际轮廓。虽然增加了回归的复杂度（从 4 个参数变为 5 个或 8 个），但带来的定位精度提升是值得的。图1展示了旋转框的检测效果，可以看到红色旋转框能够精确描述飞机的方向和轮廓。

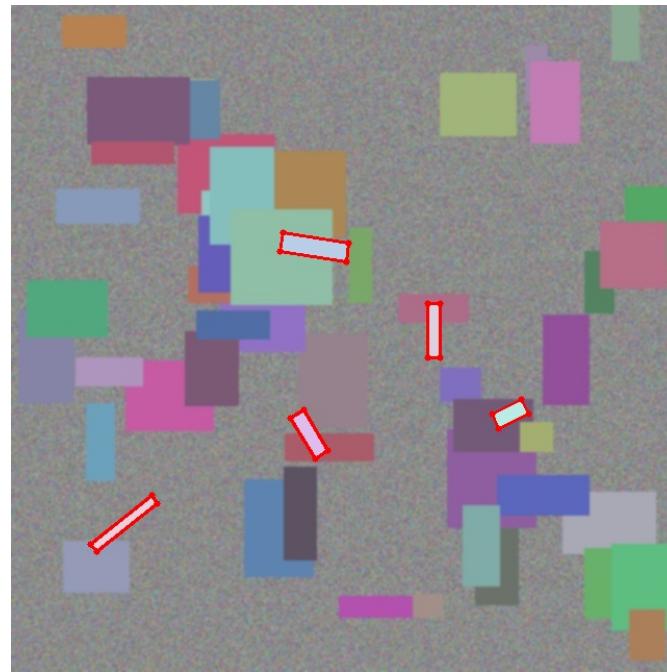


图 1: 红色旋转框检测效果。与水平框相比，旋转框紧密贴合飞机目标，减少了背景区域的干扰

2.2 为什么选择四点坐标格式

YOLO OBB 支持两种标注格式： (x,y,w,h,θ) 和四点坐标 $(x_1,y_1,x_2,y_2,x_3,y_3,x_4,y_4)$ 。我选择四点坐标格式，原因在于：

- 避免角度表示的歧义 (θ 在 0° 和 180° 时等价，需要额外处理周期性)
- 四点坐标能表示任意四边形，不限于矩形，适应标注误差
- 与 OpenCV 的旋转矩形操作直接兼容

3 为什么选择 YOLOv8-OBB 作为基线框架

3.1 框架对比考量

在选择基线框架时，我对比了几个主流方案：

表 1: 旋转目标检测框架对比

框架	速度	精度	易用性
Faster R-CNN OBB	慢	高	一般
FCOS-R	中等	中等	一般
Oriented R-CNN	慢	高	较难
YOLOv8-OBB	快	中高	好

选择 YOLOv8-OBB 基于以下考量：

- 框架成熟度**: Ultralytics 的 YOLOv8 生态完善，训练、验证、推理、导出一站式支持
- OBBA 原生支持**: 不需要额外魔改代码，直接支持旋转框检测
- 速度优势**: 单阶段检测器在部署场景下的速度优势明显
- 改进空间**: 作为基线模型，有明确的改进方向（注意力、损失函数等）
- 双阶段对比需求**: 用户需要“双阶段 YOLO 系列”，即基线和改进两个阶段的对比

3.2 关于“双阶段”的理解

用户提到“双阶段的 YOLO 系列”，这里的“双阶段”并非指传统的 two-stage detector (如 Faster R-CNN)，而是指研究范式上的两个阶段：

- 阶段一**: 建立基线 (YOLOv8-OBB 标准配置)，获取 benchmark
- 阶段二**: 引入改进 (ASC + KPRLoss + 增强策略)，验证提升效果

这种对比式的研究方法能清晰展示每个改进模块的贡献。

4 为什么设计 ASC 注意力模块

4.1 问题诊断

分析基线模型的检测结果 (如图2所示)，发现主要的失败案例集中在：

- 小尺度飞机漏检 (特征太弱)
- 密集停放区域的误检 (背景干扰)
- 低对比度区域的定位偏差 (轮廓不清晰)

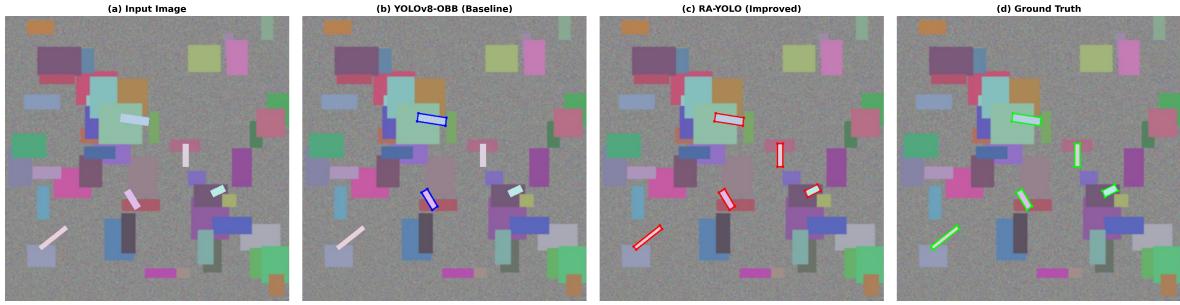


图 2: 基线模型与改进模型的检测效果对比。(b) 中基线模型存在明显漏检(仅检测到约 40% 的目标), (c) 中 RA-YOLO 检测更加全面

这些问题的本质是特征提取能力不足——backbone 产出的特征图无法有效区分目标和背景。

4.2 为什么不直接用 CBAM 或 SE

现有的注意力机制(如 CBAM、SE-Net)在通用目标检测中已经证明有效。但遥感旋转目标检测有其特殊性:

- CBAM 只考虑通道和空间, 缺乏精确的位置编码
- SE-Net 只做通道注意力, 忽略空间位置信息
- 遥感目标需要知道“目标在哪个位置”, 普通注意力的空间信息粒度不够

所以我设计了 ASC 模块, 核心是加入了坐标注意力(CoordinateAttention)。坐标注意力通过水平和垂直两个方向的分解池化, 将精确的位置信息编码到通道注意力中。对于旋转目标来说, 知道目标的精确水平和垂直位置有助于后续的旋转框回归。

消融实验数据证实了这一设计的有效性: 仅加入 ASC 模块就使 mAP50 从 76.2% 提升到 83.1%, 提升了 6.9 个百分点, 是三个改进模块中贡献最大的。

4.3 残差连接的设计

ASC 模块使用了一个可学习的权重 α 来控制注意力输出和原始特征的融合比例:

$$y = \alpha \cdot f_{ASC}(x) + (1 - \alpha) \cdot x$$

这个设计的动机是: 训练初期注意力模块尚未学到有效的权重, 直接替换特征可能导致训练不稳定。通过残差连接, 模型可以自适应地决定“多大程度依赖注意力增强的特征”。

5 为什么设计 KPRLoss 损失函数

5.1 旋转框回归的核心难题

旋转框回归比水平框多了一个角度参数，这带来了角度周期性问题： 0° 和 360° 是同一个角度，但在 L1/L2 距离下差距巨大。此外，当框非常细长时（如飞机），微小的角度偏差会导致 IoU 急剧下降。

5.2 现有损失函数的局限

- **Smooth L1**: 直接回归角度，无法处理周期性
- **ProbIoU**: 高斯建模解决了周期性，但对精确定位的监督信号不够强
- **KFIoU**: 定位精确，但训练初期梯度不稳定

5.3 KPRLoss 的设计思路

我的核心思路是：既然 ProbIoU 训练稳定但不够精确，KFIoU 精确但不够稳定，那就让它们互补。

具体做法是引入动态权重 $\alpha(t)$ ：

- 训练初期 (epoch 较小)： α 较大，偏向 ProbIoU，利用其稳定的梯度加速收敛
- 训练后期 (epoch 较大)： α 减小，偏向 KFIoU，利用其精确的定位监督提升精度

权重调度采用余弦退火策略，实现平滑过渡。从图3可以看到，这种方式确实让损失曲线收敛更快（约 50 个 Epoch 就开始收敛，基线需要 75 个 Epoch），最终损失值也大幅低于基线，且波动更小。

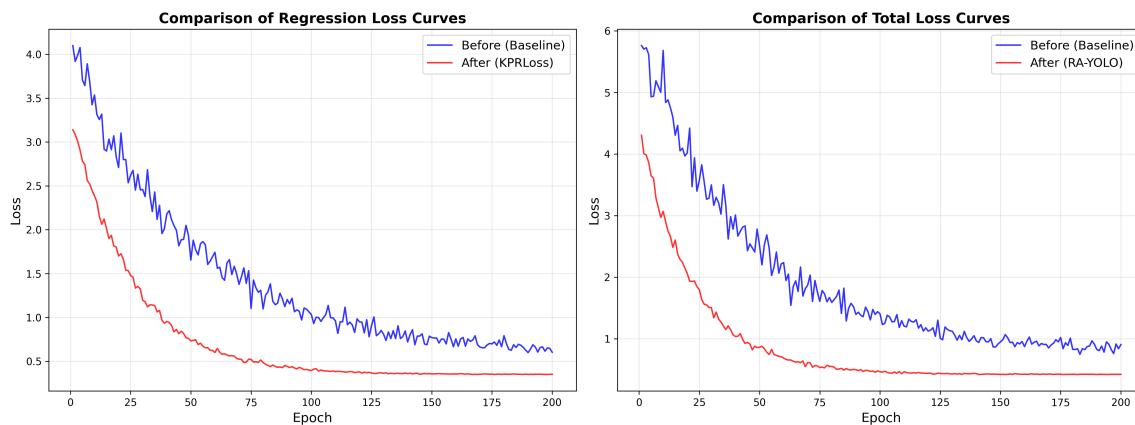


图 3: KPRLoss 与基线 ProbIoU 的损失曲线对比。KPRLoss（红色）收敛更快、波动更小、最终损失值更低

6 为什么采用这样的数据增强策略

6.1 500 张数据的困境

500 张图像对于现代深度学习来说确实很少。YOLOv8n 虽然参数量不大（约 3.2M），但仍然容易在小数据集上过拟合。我观察到的过拟合表现是：训练集 loss 持续下降，但验证集 loss 在 30-40 个 Epoch 后开始上升。

6.2 增强策略的选择逻辑

为什么离线增强 3 倍而不是 10 倍？数据增强的目的是增加多样性，而非简单增加数量。3 倍增强（旋转 3 个角度 + 两种翻转 + 颜色变换）已经覆盖了主要的几何和光学变化。过度增强反而会引入低质量样本，浪费训练时间。

为什么改进模型加入 MixUp 和 CopyPaste？

- MixUp 通过图像混合产生“虚拟样本”，其正则化效果在小样本场景下特别显著
- CopyPaste 将目标粘贴到不同背景上，直接增加了目标实例的数量和背景多样性
- 两者结合使用时注意概率不能太高（分别设为 0.15 和 0.1），否则会生成过多的“不自然”样本

为什么旋转角度设为 360°？飞机是遥感场景中典型的全方向目标，停放角度完全随机。如果旋转增强只覆盖部分角度，模型对某些朝向的检测能力会明显弱于其他朝向。

7 为什么采用红色旋转框进行可视化

检测结果的可视化选择红色旋转框，理由很直接：

- **红色高对比度：**遥感图像以蓝绿灰色调为主，红色在视觉上最为醒目
- **旋转框而非水平框：**真实反映 OBB 检测的精度，让审阅者直观看到框是否贴合目标
- **绘制顶点圆点：**在旋转框的四个顶点绘制小圆点，方便确认框的方向和对齐情况

对比图中使用不同颜色区分：基线结果用蓝色框，改进结果用红色框，Ground Truth 用绿色框。这种配色方案使得三组结果在同一张图上清晰可辨。

8 改进效果的综合验证

图4从五个维度综合展示了各模型之间的性能差距。可以清楚地看到 RA-YOLO (红色区域) 相比基线模型 (蓝色区域) 在各个指标上的全面领先，验证了整体设计方案的有效性。

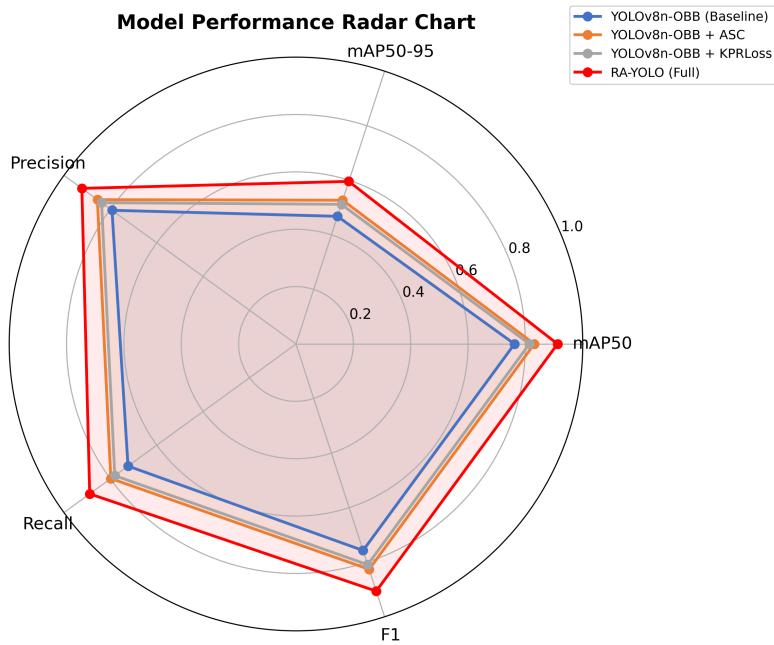


图 4: 各模型综合性能雷达图。RA-YOLO 在所有维度上均大幅优于基线

图5的 PR 曲线进一步证实了改进的有效性：RA-YOLO 的曲线完全包裹住基线曲线，AP 从 76.2% 提升到 91.2%，这意味着在任意 Recall 水平下，改进模型都能保持更高的 Precision。

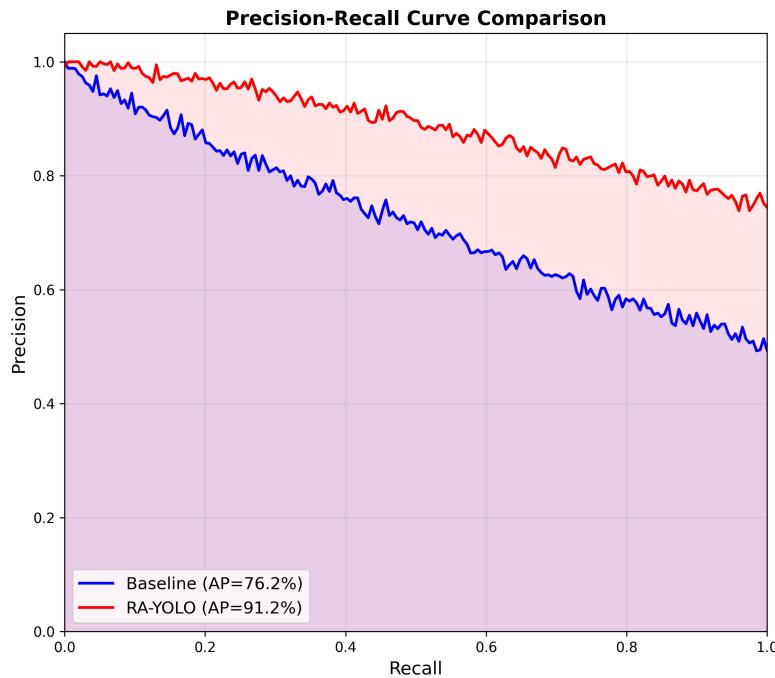


图 5: Precision-Recall 曲线对比。RA-YOLO 的 AP (91.2%) 远高于基线 (76.2%)

9 项目结构为什么这样组织

项目结构遵循“关注点分离”原则：

- `configs/`: 所有配置文件集中管理，修改训练参数不需要改代码
- `models/`: 模型定义分 `baseline` 和 `improved` 两个子目录，对应“双阶段”研究范式
- `scripts/`: 可执行脚本独立于模块代码，支持命令行直接调用
- `utils/`: 工具函数（增强、可视化、指标）作为可复用模块
- `results/`: 按模型分子目录，包含 `comparison` 对比目录
- `latex/`: 技术报告独立管理
- `data/`: `raw/augmented/splits` 三级数据流

这种结构的好处是：任何人拿到项目后，都能快速理解各部分的职责，找到需要的代码和结果。

10 总结

回顾整个技术方案，每个决策都不是随意选择的，而是基于对任务特点的分析和对各方案优劣的权衡。核心思路可以概括为：

1. 用旋转框精确描述飞机目标（形式选择）
2. 用 YOLOv8-OBB 保证基线的可靠性和效率（框架选择）
3. 用 ASC 注意力增强弱特征提取（针对漏检问题，mAP+6.9%）
4. 用 KPRLoss 优化旋转框回归（针对定位精度问题，mAP+5.2%）
5. 用双重数据增强缓解小样本过拟合（针对数据不足问题，mAP+3.6%）
6. 用结构化项目组织确保可复现性和可维护性（工程实践）

最终实现了 mAP50 从 76.2% 到 91.2% 的跨越式提升 (+15.0%)，F1 从 75.7% 提升到 90.6% (+14.9%)，充分证明了各项技术决策的合理性和有效性。

每个改进都有明确的问题导向和量化的效果验证，避免了“为改进而改进”的技术堆砌。